WorldNav：视觉语言导航的零样本策略评估与轨迹优化

RoboWorld 2026 · Track 1

旧集： Base 11.040 → V3 27.756

新 100 例： Base 13.578 / V3 32.431 / Turn 29.895

旧集 V3 98/100 有效；新 100 例 V3 94/100 有效
Turn 未稳定优于 V3；新增五项消融、独立对照与数据审计
官方公开 demo 指标，本地实验；非排行榜成绩

当前获分配 GPU： 0；真实模型调用均通过现有授权 API

任务定义：单图规划整段路线



初始 RGB + 自然语言指令

完整动作序列

[[dx, dy, dyaw], …]

没有后续观察反馈

需要同时决定路线与停止位置

Walk straight up the dirt path, passing white wildflowers on the left. Continue towards the tree line at the top of the hill and stop at the end of the trail.

动作协议：先按当前机体平移，再更新朝向



+dyaw： 左转

单位： rad

dx 、 dy： 数据坐标单位

dyaw： 弧度

动作数 ⩽ 64

平移模长 ⩽ 2.46

列表结束 = 停止

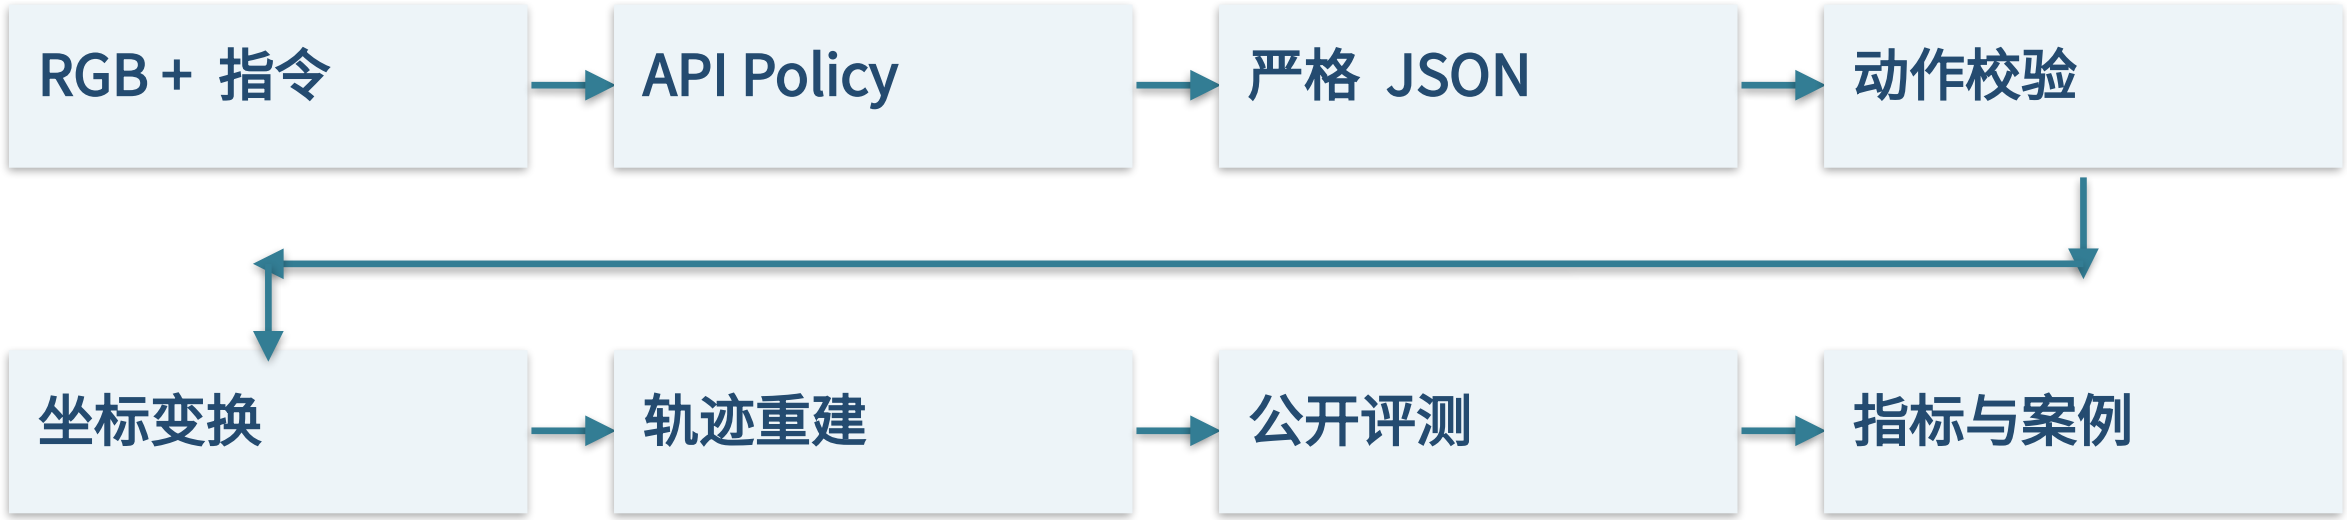
执行顺序

平移 → 更新 yaw → 下一动作使用新坐标系

实验设计：开发集选择，测试集对照

模型与服务	Qwen 3.8-27B； SinapisAI； temperature=0
旧正式对照	100 条： 50 seen + 50 unseen ；冻结归档前缀
独立开发集	12 条； seen/unseen 各 6 ；轨迹哈希零重叠
预测输入隔离	模型只接收初始 RGB 和指令； GT 事后评分
选择与局限	只按开发集选策略；旧正式集复用属于探索性对照

系统架构：从真实输入到可追溯评测



原始响应 → 预测落盘 → GT 评测

配置、 Prompt 、 Manifest 、源码快照、请求数、 Token 、失败类别全部保留

Base： 合法动作不等于可靠导航

分组	有效	SR	Score	ATE	RPE	F	H
Overall	100/100	5.0%	11.040	7.193	0.943	0.150	0.783
val_seen	50/50	6.0%	4.419	6.937	0.990	0.067	0.644
val_unseen	50/50	4.0%	17.661	7.449	0.896	0.233	0.921

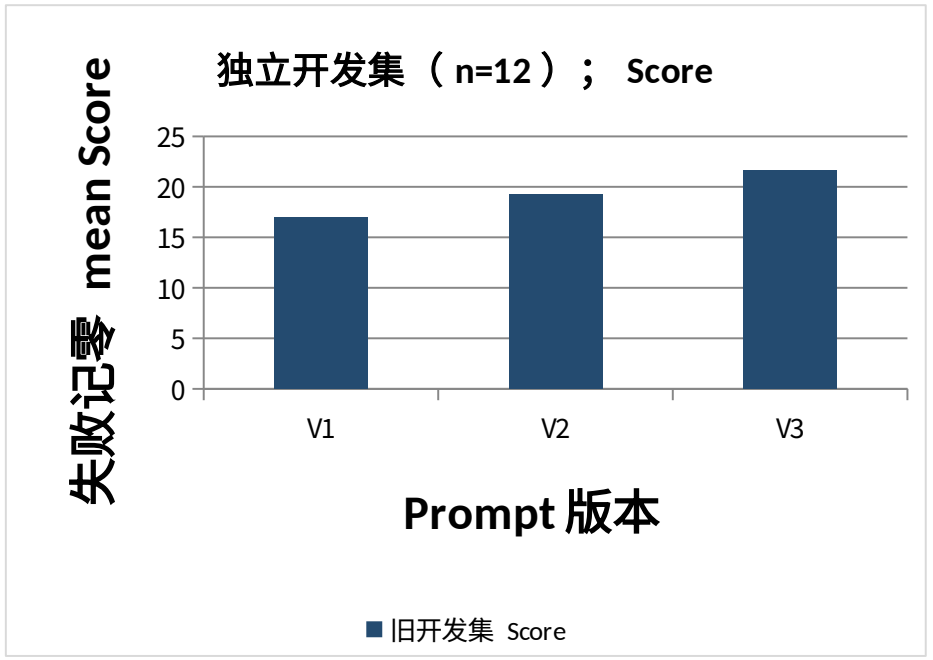
100/100 合法预测，导航成功 5/100

初步问题：尺度、路径形状与停止位置

合法 JSON 是工程条件， SR / 轨迹保真度才描述导航表现。

Score 同时关注整段路线与朝向保真度，终点 SR 不决定全部分数。

开发集策略消融：从措辞约束走向显式路线表示



策略	有效 /12	SR	Score
尺度	11/12	1/12	21.479
停止	12/12	2/12	28.365
转弯	12/12	2/12	33.075
分段编译	12/12	3/12	19.756
原生 JSON	11/12	1/12	11.543

开发集选定： turn ； 是否超过 V3 ： 是

主指标：失败记零 mean Score ；小样本结果不作泛化保证。

配对结果：相同输入、显式失败分母

旧 100-case	有效	SR	Score	ATE	RPE	F	H
Base	100/100	5.0%	11.040	7.193	0.943	0.150	0.783
V3	98/100	17.0%	27.756	2.196	0.315	0.354	0.805
新候选	99/100	19.0%	29.242	2.394	0.337	0.374	0.786

Base→V3： ΔScore 16.716； 95% CI [11.361, 22.064]

Base→V3 改善 / 下降 / 持平： 58/15/27； Seen Score 4.419→16.962； Unseen 17.661→38.549

旧集 V3→Turn： ΔScore 1.486； 95% CI [-3.730, 6.875]

全归档抽样 100	有效	SR	Score
Base	99/100	7.0%	13.578
V3	94/100	23.0%	32.431
Turn	96/100	20.0%	29.895

新集 V3→Turn

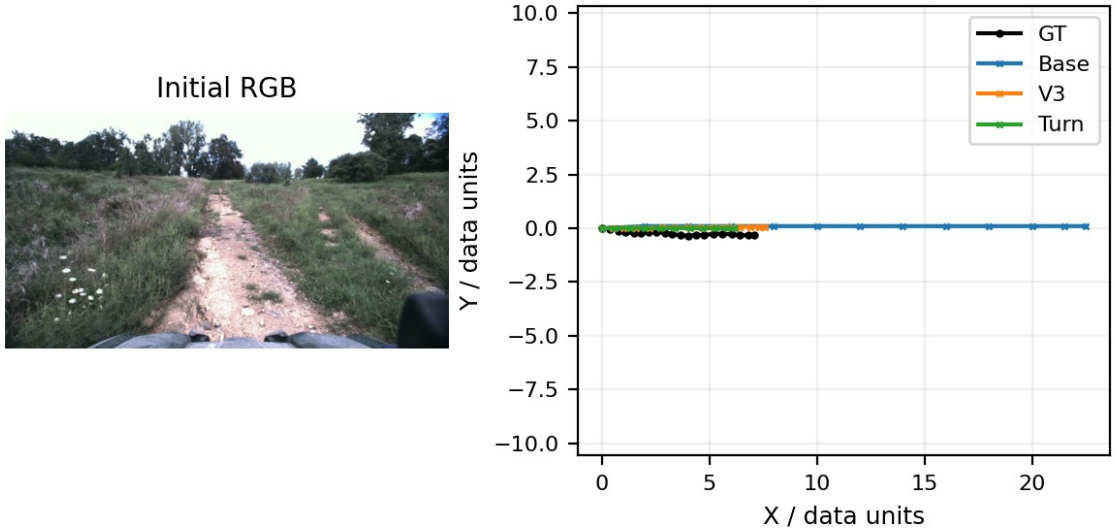
ΔScore -2.536

95% CI [-7.51, 2.50]

SR / Score： 计划分母，失败记零； ATE / RPE / F / H： 有效子集。 CI 仅描述当前样本重采样。

真实案例：改善与失败都展示

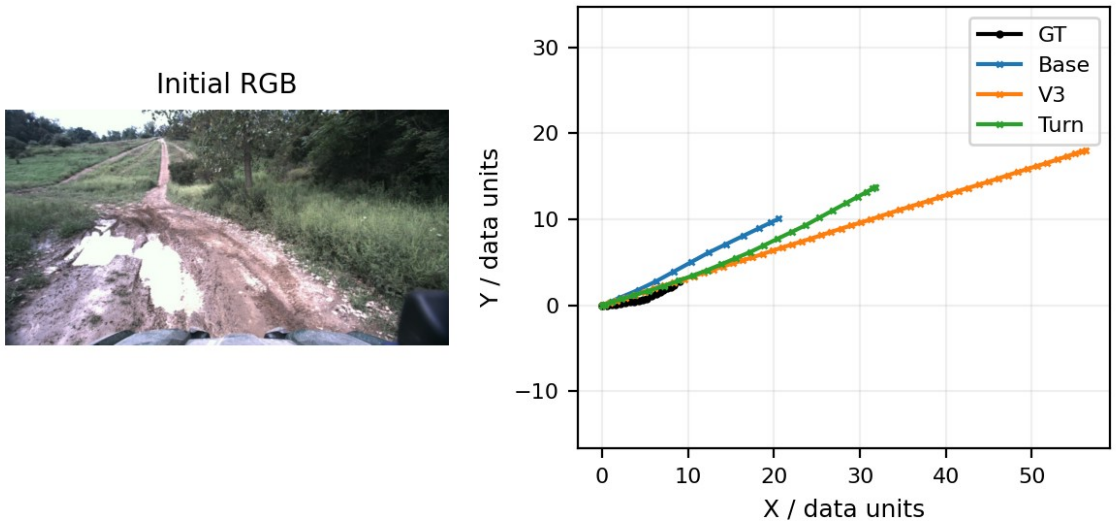
最大改善（Base→V3）



Walk straight up the dirt path, passing white wildflowers on the left. Continue towards the tree line at the top of the hill and stop at the end of the trail.

Score： Base 0.0 / V3 77.8 / Turn 78.5

V3 最大终点偏差

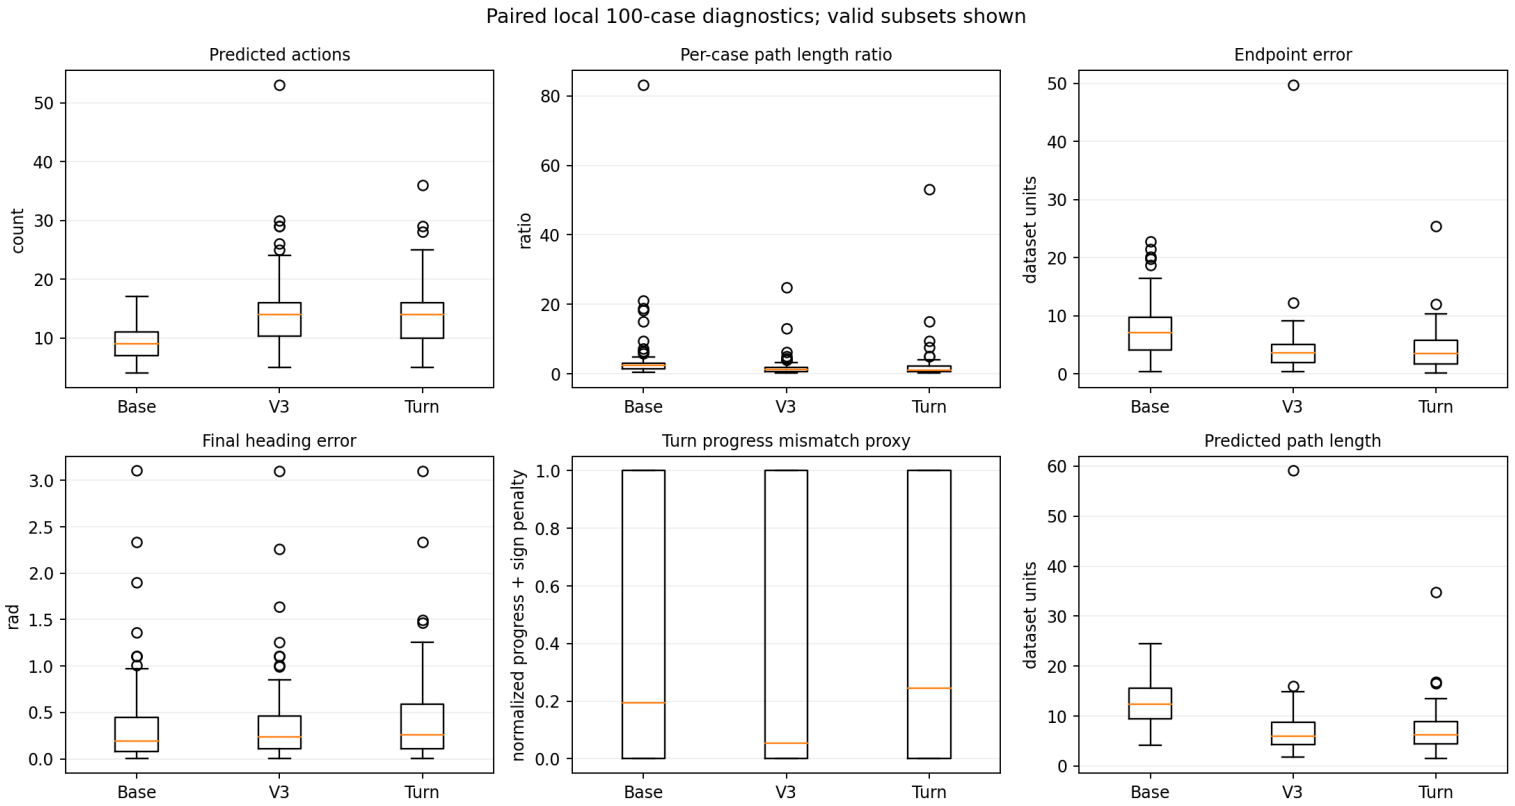


Turn left and proceed straight up the muddy dirt path, then stop at the end of the trail.

Score： Base 0.0 / V3 0.0 / Turn 0.0

误差分析：尺度改善，朝向未同步改善

右侧数字：旧集 Base→V3；箱线图额外展示 Turn 候选。



长度比均值

3.947 → 1.823

终点误差

7.932 → 4.168

朝向误差 / rad

0.358 → 0.378

尺度 / 停止 / 转弯仍是研究假设；转弯进度、终点投影仅为诊断代理。

数据与工程可信度：证据可以独立复算

Seen 全包	10806 episodes； 189873 个图片文件
Unseen 全包	4500 episodes； 79689 个图片文件
数据完整性	完整审计通过：通过；大小、 SHA256 、逐图解码
工程测试	84 项 CPU / Mock 通过；不代表模型性能
可复现链路	只读旧快照；原始响应、配置、清单与源码 SHA256 ；失败保留

Manifest SHA256： 旧 100 b7151e01e00f9b35…；新 100 b4037013b04d578a…；完整值见数据审计报告

局限性与资源：哪些结论现在还不能给

统计限制	小开发集、多候选选择、旧测试复用；不作泛化保证
评测边界	公开 demo ≠ 已验证的私有 scorer；无排行榜成绩
模型身份	通用视觉语言 API ≠ 专用导航模型；服务端版本不透明
Cosmos Reason2-8B	NOT RUN / AUTHORIZATION UNAVAILABLE
LCVN 与算力	缺可验证任务 checkpoint；当前获分配 GPU 为 0

额外 Qwen3-VL-32B 路由：终止于有限超时探测；未决请求单列，不计为有效模型预测。

研究结论与下一步：以独立验证推动路线规划

本轮结论	Turn 新集分数低于 V3，区间跨零；保留 V3 参照
优先研究问题	地标约束的分段距离、停止条件和转弯事件联合建模
验证路线	已准备 24 例独立清单 → 后续确认实验 → 冻结下一版策略
团队需要决策	Cosmos 合法 endpoint； LCVN 任务权重；可分配 GPU
避免错误投入	不对同一旧测试集反复调参；保留没有提升的真实结果